Universidade do Minho
Departamento de Informática

Pipeline de Extração de Conhecimento

Perfil SDW @ 2024/2025, 2º sem

Universidade do Minho
Departamento de Informática

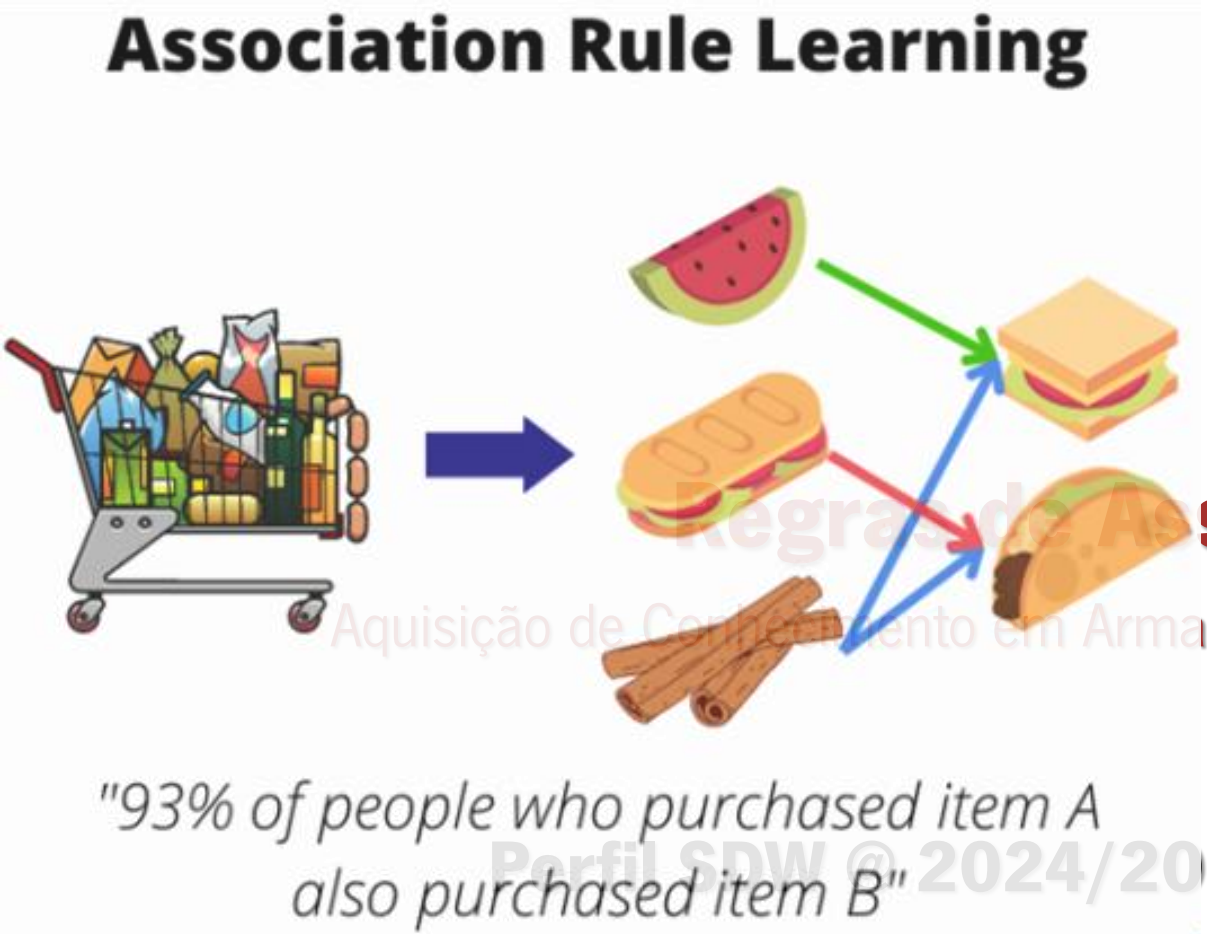

Regras de Associação

Aquisição de Conhecimento em Armazéns de Dados

Perfil SDW @ 2024/2025, 2º sem

Universidade do Minho
Departamento de Informática

Metodologias de Análise de Dados

Extração de Conhecimento

- Data Mining – Descoberta de Conhecimento em Bases de Dados
  Manuel Filipe Santos, Carla Azevedo

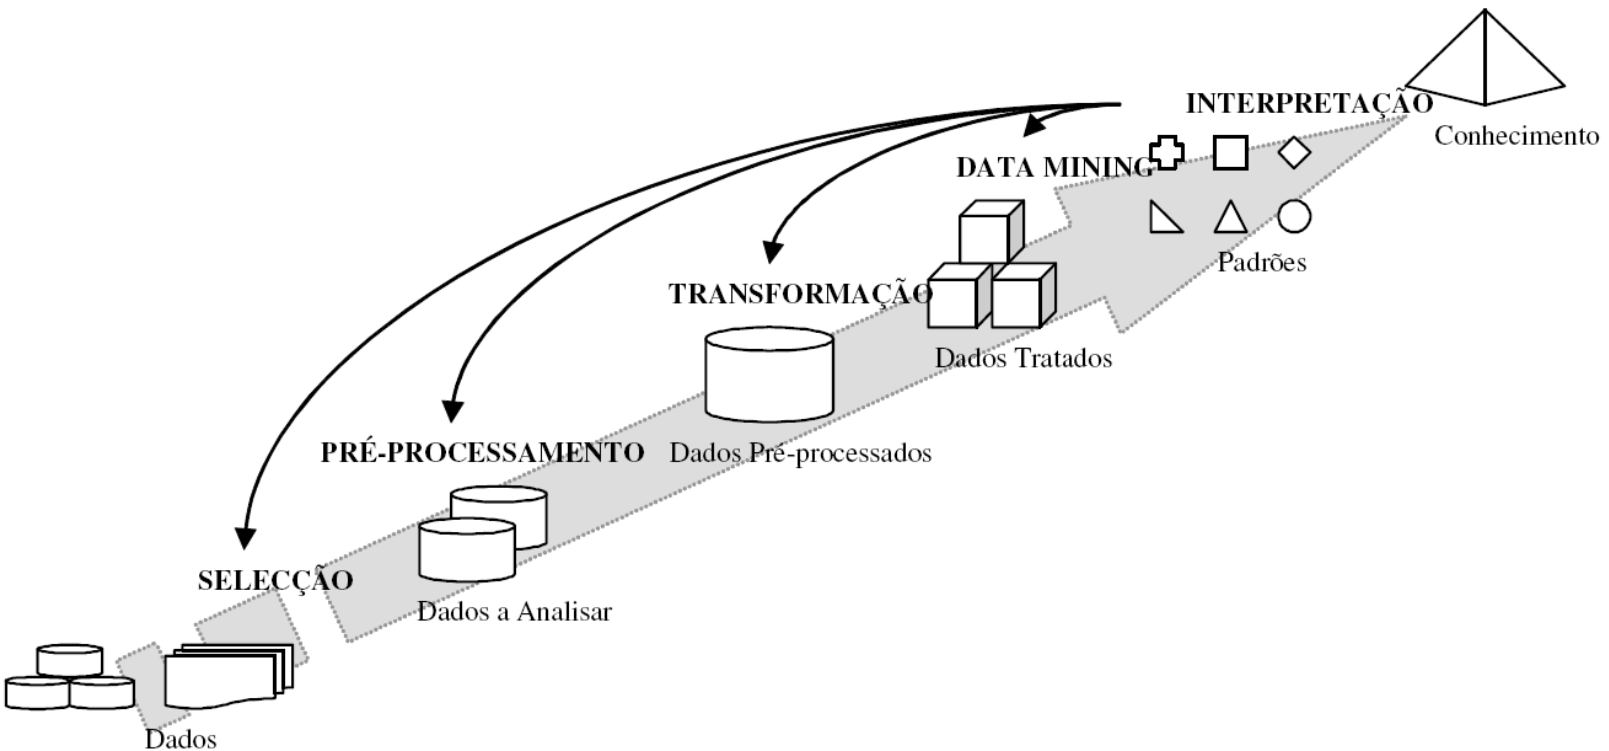

Metodologias para Análise de Dados

- Uma **Metodologia para Análise de Dados** descreve e cria **um conjunto de passos** pelos quais deverá passar o desenvolvimento de um **Projeto de Aprendizagem por Máquinas (*Machine Learning*)** para a resolução de problemas.

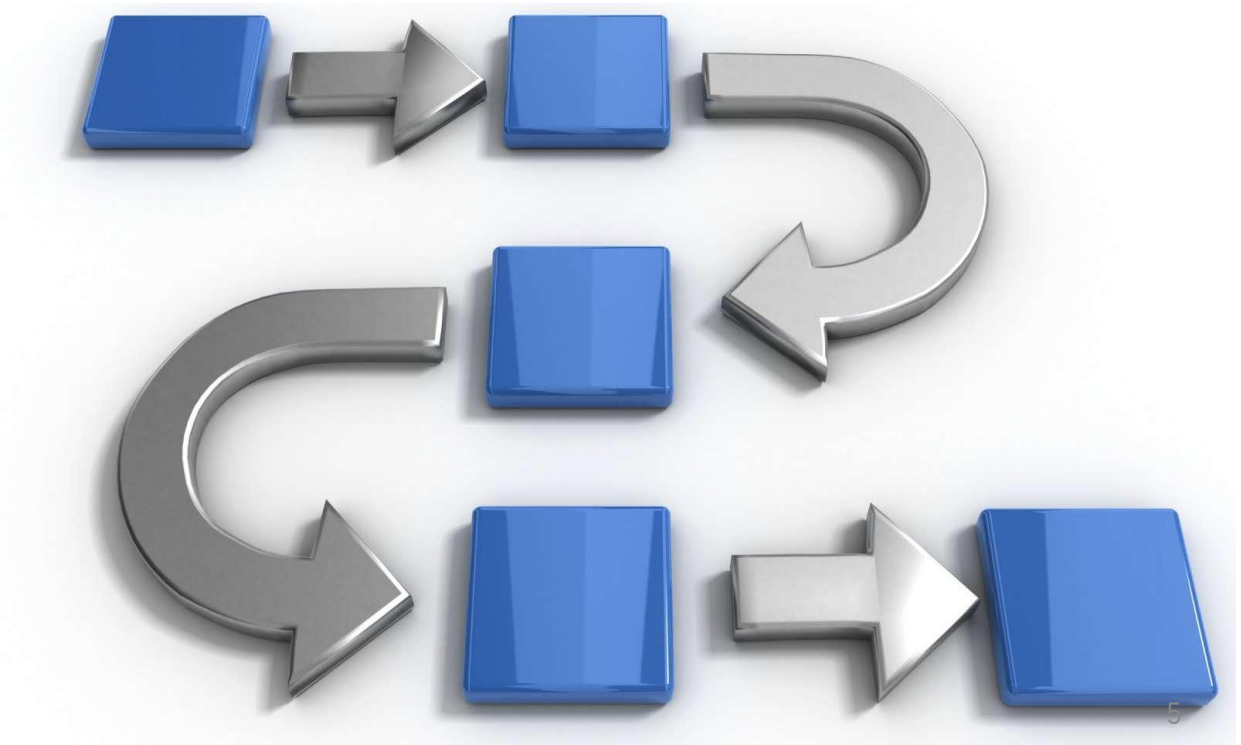

Porquê?

- Enquadrar um processo de Extração de Conhecimento ao abrigo de uma metodologia:
  - Garante maior robustez;
  - Facilita a sua compreensão, implementação e desenvolvimento;
  - Permite a replicação de processos;
  - Auxilia no planeamento e na gestão do projeto;
  - Confere "maturidade" ao processo;
  - Encoraja a adoção de melhores práticas.

CRISP-DM

- **CR**oss **I**ndustry **S**tandard **P**rocess for **D**ata **M**ining (Daimler Chrysler, SPSS, NCR)
- Objetivos:
  - Definir um processo de Análise de Dados para a indústria;
  - Construir e disponibilizar ferramentas de apoio;
  - Assegurar a qualidade dos projetos de Análise de Dados;
  - Reduzir os conhecimentos específicos necessários para conduzir um processo de Análise de Dados.

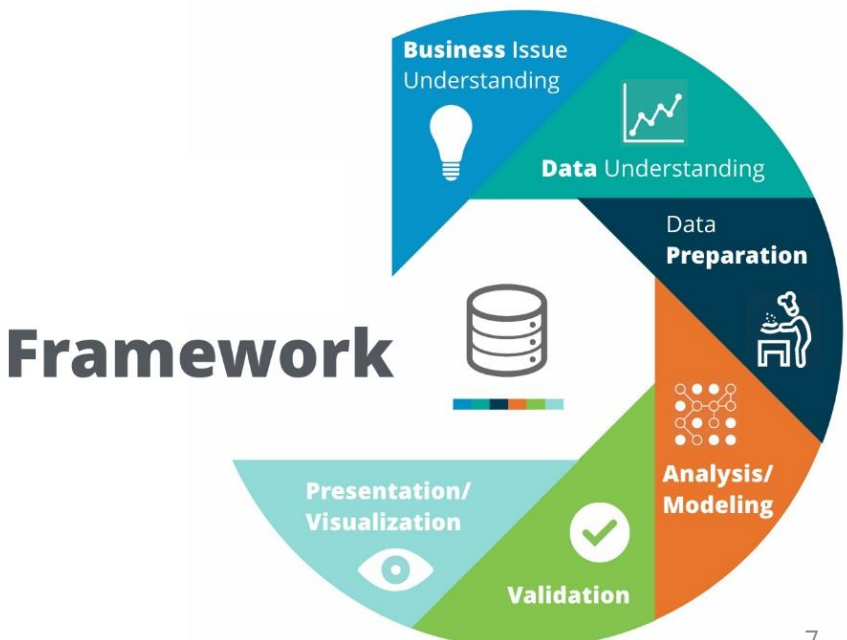

CRISP-DM
Ciclo de vida

- O CRISP-DM é um modelo de processos com vista a definir um "guião" para o desenvolvimento de projetos de AD, que se desenrola em 6 etapas:
  - Estudo do negócio;
  - Estudo dos dados;
  - Preparação dos dados;
  - Modelação;
  - Avaliação;
  - Desenvolvimento.

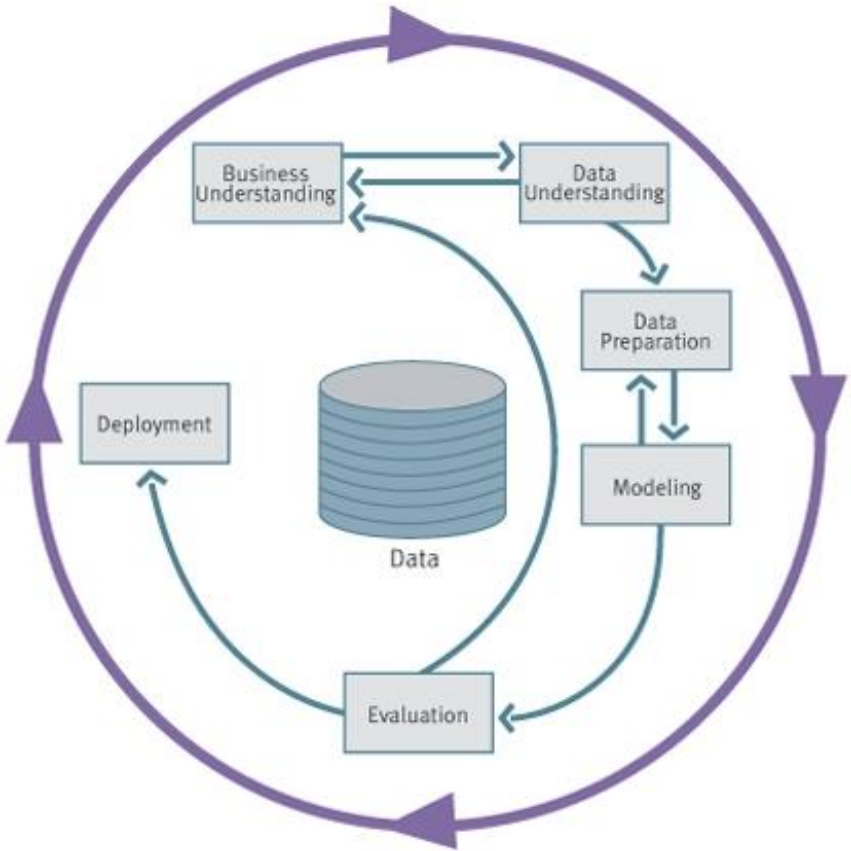

CRISP-DM
Ciclo de vida

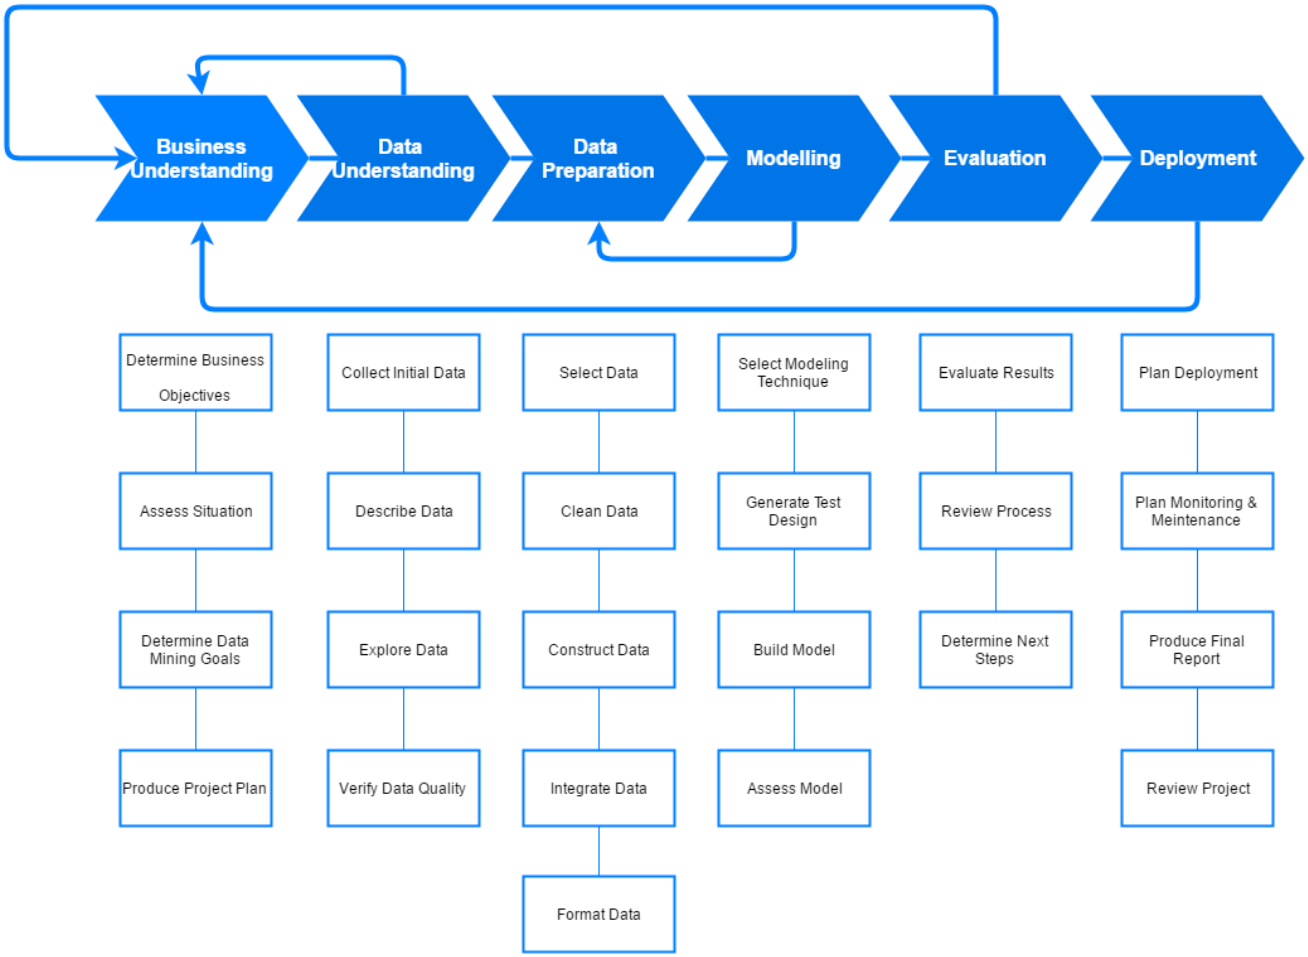

Metodologia CRISP-DM

- "CRISP-DM 1.0: Step-by-step data mining guide",
  Pete Chapman (NCR),
  Julian Clinton (SPSS),
  Randy Kerber (NCR),
  Thomas Khabaza (SPSS),
  Thomas Reinartz (DaimlerChrysler)
  Colin Shearer (SPSS)
  Rüdiger Wirth (DaimlerChrysler)
- CRISP-DM (pdf file)
- IBM SPSS Modeler CRISP-DM Guide

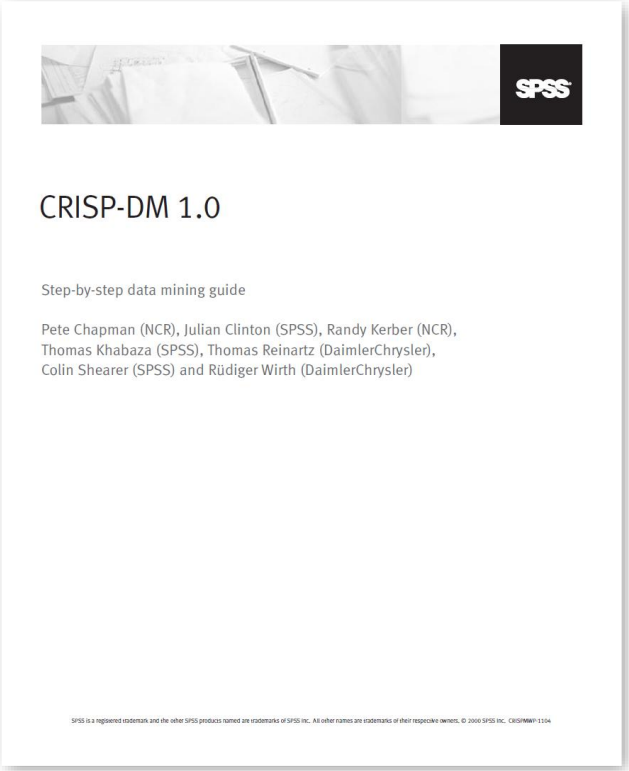
SPSS

CRISP-DM 1.0

Step-by-step data mining guide

Pete Chapman (NCR), Julian Clinton (SPSS), Randy Kerber (NCR),
Thomas Khabaza (SPSS), Thomas Reinartz (DaimlerChrysler),
Colin Shearer (SPSS) and Rüdiger Wirth (DaimlerChrysler)

SPSS is a registered trademark and the other SPSS products named are trademarks of SPSS Inc. All other names are trademarks of their respective owners. © 2000 SPSS Inc. CRISPWP-1104

SEMMA

- **S**ample, **E**xplore, **M**odify, **M**odel and **A**ssess;
- Produto de *Data Mining* desenvolvido pelo SAS Institute Inc.;
- Definição SAS:
  - "*Data Mining* é o processo de **extrair conhecimento e relações complexas** de grandes volumes de dados."
- Motivação:
  - necessidade de definir, padronizar e integrar sistemas ou processos de *Data Mining* nos ciclos de produção.
- Desenvolvimento focado na ferramenta SAS Enterprise Miner.

O processo SEMMA

- Divide o processo de *Data Mining* em 5 etapas:
  - *Sample*/ Amostragem;
  - *Explore*/ Exploração;
  - *Modify*/ Modificação;
  - *Model*/ Modelação;
  - *Assess*/ Avaliação.

O processo SEMMA

- Divide o processo de *Data Mining* em 5 etapas:
  - *Sample*/ Amostragem;
  - *Explore*/ Exploração;
  - *Modify*/ Modificação;
  - *Model*/ Modelação;
  - *Assess*/ Avaliação.

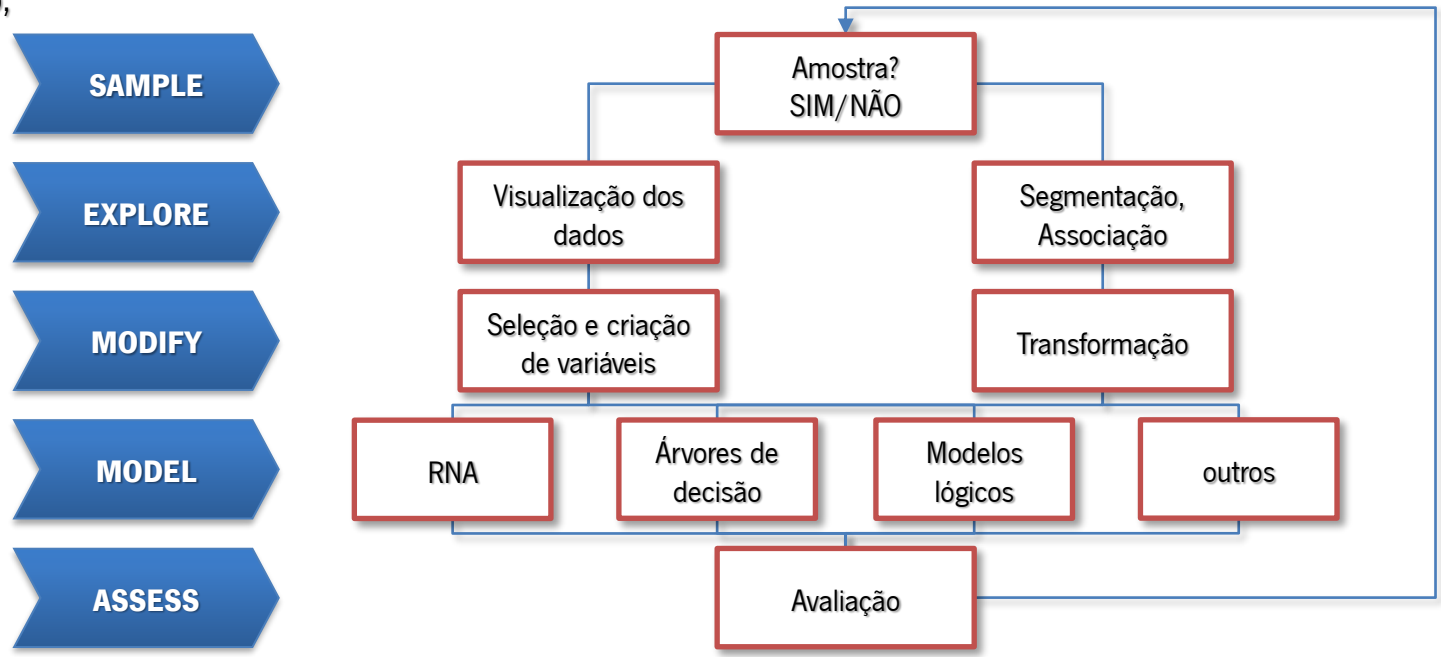

CRISP-DM versus SEMMA

- Fases CRISP-DM:
  - Estudo do negócio;
  - Estudo dos dados;
  - Preparação dos dados;
  - Modelação;
  - Avaliação;
  - Desenvolvimento.

- Processo SEMMA:
  - Amostragem;
  - Exploração;
  - Modificação;
  - Modelação;
  - Avaliação.

Universidade do Minho
Departamento de Informática

Exploração de Dados

Exploração dos dados

- Porquê?
  - Compreender os dados e as suas características;
  - Analisar e avaliar a qualidade dos dados;
  - Perceber padrões e informações relevantes;

https://www.jaspersoft.com/articles/what-is-data-exploration

Exploração dos dados

- Como?
  - Análise uni-variada:
    - Tendências centrais: average, mode, median…
    - Dispersão estatística: variance, standard deviation, interquartile range…
    - Distribuição de probabilidades: Gaussian, Uniform, Exponential…
  - Análise multi-variada:
    - Variância;
    - Correlação/Dependência
  - Visualização de dados:
    - tables, charts, boxplots, scatter plots, histograms, …

Exploração dos dados

- Análise uni-variada:
  - Tendências centrais: average, mode, median...
  - Dispersão estatística: variance, standard deviation, interquartile range...
  - Distribuição de probabilidades: Gaussian, Uniform, Exponential...

- Criar uma descrição estatística de cada variável relevante do problema;

```
orders_df.describe()
```

	order_id	user_id	order_number	order_dow	order_hour_of_day	days_since_prior_order
count	3.421083e+06	3.421083e+06	3.421083e+06	3.421083e+06	3.421083e+06	3.214874e+06
mean	1.710542e+06	1.029782e+05	1.715486e+01	2.776219e+00	1.345202e+01	1.111484e+01
std	9.875817e+05	5.953372e+04	1.773316e+01	2.046829e+00	4.226088e+00	9.206737e+00
min	1.000000e+00	1.000000e+00	1.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00
25%	8.552715e+05	5.139400e+04	5.000000e+00	1.000000e+00	1.000000e+01	4.000000e+00
50%	1.710542e+06	1.026890e+05	1.100000e+01	3.000000e+00	1.300000e+01	7.000000e+00
75%	2.565812e+06	1.543850e+05	2.300000e+01	5.000000e+00	1.600000e+01	1.500000e+01
max	3.421083e+06	2.062090e+05	1.000000e+02	6.000000e+00	2.300000e+01	3.000000e+01

Exploração dos dados

- Análise multi-variada:
  - Variância;
  - Correlação/Dependência

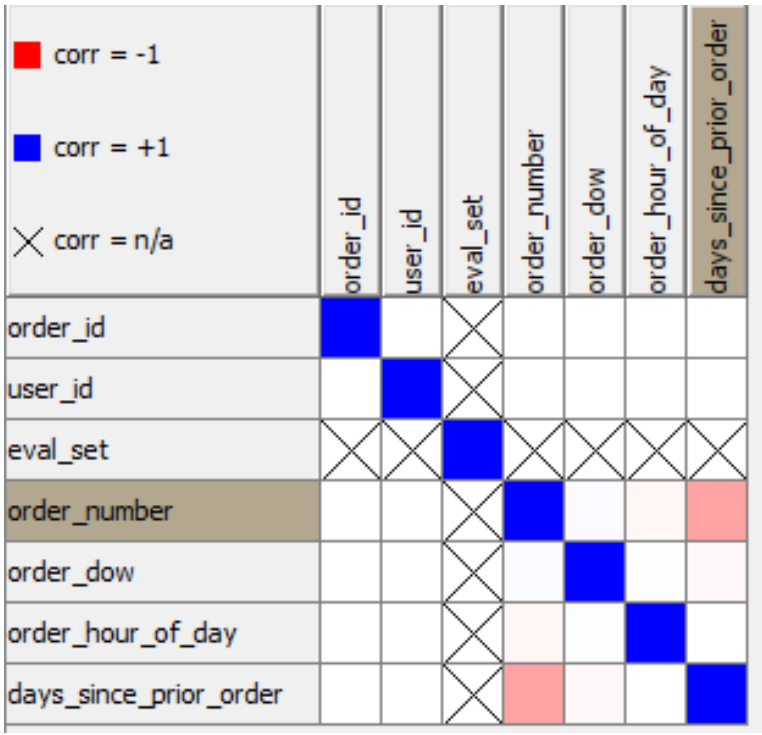

Covariância

- A covariância mede quanto duas variáveis (atributos, colunas, *features*) dependem uma da outra

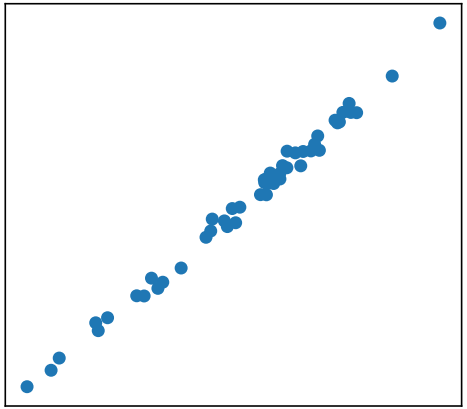

(covariância positiva)

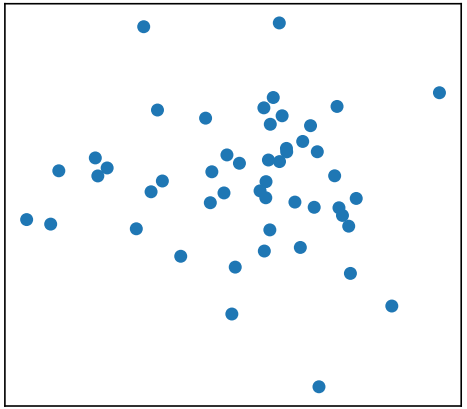

(covariância nula)

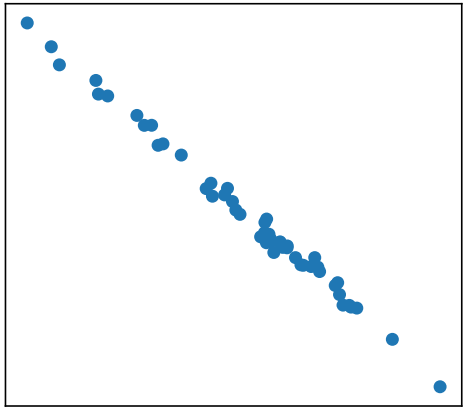

(covariância negativa)

Covariância & Correlação

- Interpretar a **covariância** é difícil:
  - Baixa covariância (próxima de 0) significa que não há muita correlação entre as duas variáveis;
  - Alta covariância (muito superior a 0, ou negativa para relações inversas) significa que existe uma correlação entre as variáveis;

- A **covariância** indica como duas variáveis mudam de valor, quando comparadas conjuntamente;

- Interpretar a **correlação** é mais fácil:
  - Valor de normalização da covariância dividido pelos desvios padrão de ambas as variáveis:
    - Correlação = -1: correlação inversa perfeita
    - Correlação = 0: sem correlação
    - Correlação = 1: correlação perfeita

- A **correlação** indica a proximidade do comportamento entre duas variáveis;

Tanto a **covariância** como a **correlação** medem o relacionamento e a dependência entre duas variáveis;

https://builtin.com/data-science/covariance-vs-correlation

Correlação

- Mas... a correlação não implica causalidade!!!
  - Apenas uma experiência controlada e aleatória pode fornecer informações sobre a causalidade;
  - Usar a correlação para decidir quais as experiências a realizar.

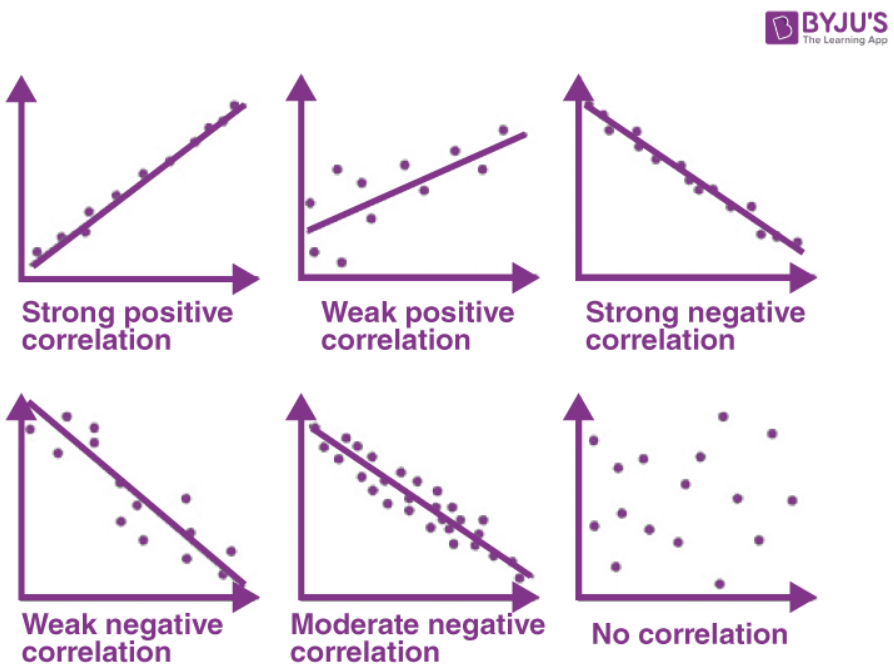

https://byjus.com/maths/correlation

Matriz de Correlação

- Queremos manter atributos (*features*) altamente correlacionados?
- Ambos positivos e negativamente correlacionados?
- E quanto à correlação entre os atributos dependentes e independentes?
- ...

Universidade do Minho
Departamento de Informática

Preparação de Dados

Porquê preparar os dados?

- Os dados recolhidos do “mundo real”:
  - são incompletos:
    - falta de valores em alguns atributos;
    - falta de alguns atributos;
    - dados agregados ou generalizados;
    - Nº de filhos: “”;
  - contêm lixo:
    - identificam valores impossíveis;
    - Salário: -1.000EUR;
    - Data: 31/novembro/2017;
  - podem conter inconsistências:
    - encontram-se discrepâncias entre valores ou nomes;
    - Idade = 35; Data de nascimento = 31/maio/1969;
    - Sexo: “M/F”; “0/1”; “Masculino/Feminino/Desconhecido”;
    - diferenças entre valores de registos duplicados.

Tipos de dados

- Nominais;
- Categorias;
- Ordinais;

Qualitativos

- Intervalos;
- Rácios.

Quantitativos

Discretos

Contínuos

Maior conteúdo informativo

Tarefas na preparação de dados

- Discretização/Enumeração;
- Limpeza;
- Integração;
- Transformação;
- Redução.

Preparação Avançada de Dados

- Redimensionamento de atributos/ *Feature scaling*
- Deteção de valores atípicos/ *Outlier detection*
- Seleção de Atributos/ *Feature selection*
- Tratamento de Valores em Falta/ *Missing Values treatment*
- Enumeração de Valores Nominais/ *Nominal value discretization*
- Divisão em Intervalos/ *Binning*
- Engenharia de Atributos/ *Feature Engineering*

Preparação de Dados

- Adequar os dados às técnicas de análise;
- Adaptar os dados às ferramentas;
- Selecionar os dados que representam conhecimento;
- Sintetizar dados que tornem a realidade mais inteligível;

- "Preparação do preparador"!

Referências bibliográficas

- "CRISP-DM 1.0: Step-by-step data mining guide", Pete Chapman, Julian Clinton, Randy Kerber, Thomas Khabaza, Thomas Reinartz, Colin Shearer, Rüdiger Wirth.
- SAS Enterprise Miner:
  www.sas.com/technologies/analytics/datamining/miner/semma.html
- Data Mining Group (DMG):
  www.dmg.org
  www.dmg.org/faq.html
- Data Preparation for Data Mining
  Dorian Pyle
- Data Mining: Concepts and Techniques
  Jiawei Han, Micheline Kamber
- Data Mining: Practical Machine Learning Tools and T
  Ian Witten, Eibe Frank
- Data Mining: Descoberta de Conhecimento em BDs
  Manuel Filipe Santos, Carla Azevedo

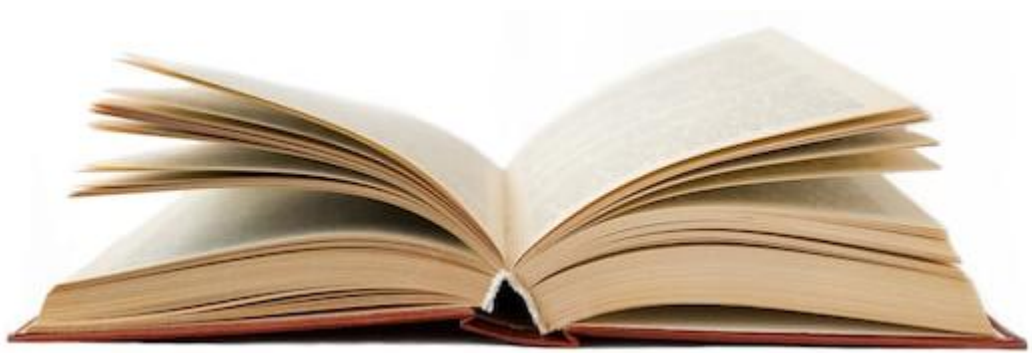

Universidade do Minho
Departamento de Informática

Pipeline de Extração de Conhecimento

Perfil SDW @ 2024/2025, 2º sem